

血压研究数据采集手册

与 PulseDB 对齐的 ECG 与 PPG 采集

Jingyi Guo、Carlos Alberto Lopez Hernandez、Brian Rabideau

1. 需要采集什么

每条完整记录由一段 10 秒 ECG/PPG 信号和一次配对的上臂袖带血压读数组成。设备保存波形，操作人员在纸上记录血压和对应的片段编号，再用编号将二者合并。

记录方式	内容
设备	同步采集两路信号，每秒 125 点，每段每路 1,250 点。
纸质表格	参与者随机编号、访问次数、测量轮次、片段编号、SBP、DBP、完成状态及采集备注。
场次设置	设备型号、固件、通道单位、PPG LED 通道、采样率、信号极性和时间同步设置。

采集顺序

按获批研究流程和已完成安全审核的设备配置开展采集。分配随机编号，确认访问次数，安置传感器和袖带。完成规定的坐位静息后，检查两路实时信号。保存袖带充气前紧邻的 10 秒信号，再把显示的 SBP、DBP 记录到对应片段编号下。配对测量期间保持坐位和静止。计划每次访问三组配对测量，每人两次访问，间隔 3-14 天。袖带测量间隔遵循获批流程。未成功的轮次记录原因；流程允许的重测使用新的片段编号。配对波形在充气前结束，因此不包含袖带充气造成的扰动。访问结束时逐行核对纸质记录与电子文件，确认文件可读取，再转存到获批的 ND 受限存储。纸张照片可用于录入血压记录；电子波形文件仍需一并保留。

2. 文件格式与字段

CSV 是本项目的数据接口。PulseDB 原文件为 MATLAB .mat 数组；官方子集的 Subset.Signals 包含 ECG、PPG 和 ABP，标签位于 Subset.SBP 和 Subset.DBP。本模型只使用 ECG、PPG 预测，公共数据的血压标签来自 ABP。

A. 设备保存的原始片段

```
time_s,ecg_raw,ppg_raw
```

共 1,250 行数值，时间间隔为 0.008 秒。ECG、PPG 对应相同时间戳，原始幅度单位记录在场次设置中。同时保留连续采集源文件。

B. 纸质记录转录表

```
participant_id,visit,cycle,segment_id,  
waveform_file,SBP,DBP,status
```

实际文件的表头在同一行。waveform_file 为相对文件路径，SBP、DBP 单位为 mmHg。完整可用的配对记录标为 accepted。访问和轮次信息保留在此表中，不作为模型输入。

C. 输入模型的宽格式 CSV

列位置	字段名 / 命名规则	含义
1-4	dataset, participant_id, segment_id, fs_hz	来源、参与者、片段和采样率
5-6	SBP, DBP	参考血压, mmHg
7-1256	ecg_0000 ... ecg_1249	按时间排列的 ECG
1257-2506	ppg_0000 ... ppg_1249	按时间排列的 PPG

完整的 2,506 个列名见 complete_header.csv，column_dictionary.csv 逐列说明。样本索引 j 对应 j/125 秒。两路信号均为滤波并归一化后的无量纲幅度。标签和编号不输入预测模型。

3. 读取 20 条真实片段记录

以下为导出程序选出的开发训练数据中前 20 条有效记录，均为真实数据。同一公共参与者的每一行代表不同的 10 秒片段。完整 CSV 还包含每行的 2,500 个波形数值。

Row	Participant	SBP	DBP
1	p000001_1	130.71	87.99
2	p000001_1	129.74	89.15
3	p000001_1	131.32	83.79
4	p000001_1	157.72	104.95
5	p000001_1	123.77	76.92
6	p000001_1	130.37	86.78
7	p000001_1	119.83	80.51
8	p000001_1	126.36	85.51
9	p000001_1	132.65	86.41
10	p000001_1	121.11	76.66
11	p000001_1	133.50	83.99
12	p000001_1	160.56	105.70
13	p000001_1	112.99	74.76
14	p000001_1	148.09	95.13
15	p000001_1	118.82	78.91
16	p000001_1	112.82	66.31
17	p000001_1	110.42	74.19
18	p000001_1	119.83	82.93
19	p000001_1	116.07	69.26
20	p000001_1	117.57	77.25

第一行的参与者为 p000001_1，片段为 official_train_row_1。标签是 130.71/87.99 mmHg。模型读取该行的 ECG/PPG 数组，输出两个预测血压值。real_20_segments.csv 保存完整记录；real_20_segments_metadata.csv 为上表的简版。片段编号中的行号指官方 MATLAB 训练子集的一起始行号，并非原始记录中的 SegmentID。提取信息见 provenance.json。

4. 读取波形数值

这是上一页第一条片段的另一种展开方式。此处一行代表一个采样时刻，而非一个片段。前 20 点覆盖 0.000-0.152 秒。

Index	Time (s)	ECG	PPG
0	0.000	0.127385	0.038952
1	0.008	0.144529	0.049507
2	0.016	0.161971	0.064195
3	0.024	0.183065	0.083477
4	0.032	0.201643	0.107861
5	0.040	0.210779	0.137500
6	0.048	0.212760	0.172536
7	0.056	0.204401	0.212786
8	0.064	0.176399	0.257863
9	0.072	0.135182	0.307352
10	0.080	0.099445	0.360438
11	0.088	0.078871	0.416186
12	0.096	0.074263	0.473611
13	0.104	0.082308	0.531529
14	0.112	0.093708	0.588727
15	0.120	0.101428	0.644077
16	0.128	0.101906	0.696453
17	0.136	0.094458	0.744762
18	0.144	0.110324	0.788136
19	0.152	0.218902	0.825858

例如，样本 1 在宽格式中分别存于 ecg_0001 和 ppg_0001，均对应 0.008 秒。将连续数值按时间连线便得到波形。这些数值是归一化信号幅度，不是血压。导出的实际数值保留 float32 精度，本页为便于阅读显示六位小数。real_20_samples.csv 包含完整数值及对应参与者 / 片段编号。

5. 纸质采集记录表

每次访问打印一张。填写随机编号而非姓名，参与者在后续访问使用相同编号。

参与者编号：_____ 访问次数：_____

采集配置编号：_____

轮次	片段编号	SBP	DBP	状态 / 备注
1				
2				
3				
重测				
重测				
重测				

结束前核对

确认每条完整记录均有对应波形文件，血压数值清楚可读。标明未完成和重测轮次，保留备注。修改转录错误时保留原始记录。用照片录入时拍清整张表，并对照照片核实整理后的数值表。命名示例：ND017_V1_C2 表示参与者 ND017 的第 1 次访问、第 2 轮，电子文件保存为 ND017_V1_C2.csv。重测可命名为 ND017_V1_C2_R1，纸上填写完全相同的编号。实际参与者文件和照片存放在研究受限存储中；公开 GitHub 的 nd 文件夹仅保存模板与转换说明。

6. 数据转换与预测

在模型目录中创建 Python 环境并安装 requirements。当前选定模型为 `cnn_full`，即双通道残差 CNN。

```
python predict.py "../../../data/PulseDB/examples/real_20_segments.csv"
    --output predictions.csv --format filtered
python convert_nd.py /restricted/reference_log.csv
    --output /restricted/nd_segments.csv
python predict.py /restricted/nd_segments.csv
    --output /restricted/nd_predictions.csv --format filtered
```

此处命令为排版换行，执行时每条输入一行。macOS 如遇 XGBoost/OpenMP 加载问题，可用 `sh run.sh predict.py ...` 启动；当前选中的 CNN 本身不需要 XGBoost。ND 转换器对 ECG 使用 0.5-40 Hz 四阶 Butterworth 滤波，对 PPG 使用 0.5-8 Hz 四阶 Chebyshev II 滤波（阻带参数 20 dB），再逐通道归一化至 0-1。公共数据使用已提供的滤波通道；该窗口级转换器是明确定义的部署实现，不代表与原数据处理链完全等价。

模型实测结果

评估集	SBP MAE	DBP MAE
官方跨人测试集	12.46	8.46
排除前期接触者后	12.44	8.39
AAMI 命名子集	19.34	13.17

误差单位为 mmHg。官方测试集为 144 人、57,600 段，其中 3 人出现在前期探索工作中；排除后为 141 人、56,400 段。AAMI 命名子集为 116 人、666 段，其名称不代表认证。该模型为研究预测器，ND 迁移效果和树莓派延迟尚待实测。来源：PulseDB repository; official author-hosted subsets; Wang et al., *Frontiers in Digital Health* (2023), DOI: 10.3389/fdgth.2022.1090854. Public sample data: CC BY-NC-SA 4.0; license and attribution accompany the examples.

7. V1 完整误差指标

V1: 高分辨率双通道残差一维 CNN，使用标准化目标的 MSE 训练。以下指标来自已选定模型的保存预测，权重未变。

官方跨人测试集：144 人 / 57,600 段

指标	SBP	DBP
MAE	12.46	8.46
Bias	-1.92	-1.64
误差 SD	15.89	10.66
误差不超过 5 mmHg (%)	26.06	37.24
误差不超过 10 mmHg (%)	48.80	66.11
误差不超过 15 mmHg (%)	67.55	84.62
参与者平均 MAE	12.46	8.46
参与者 MAE: 中位数	11.02	7.32
参与者 MAE: 第 90 百分位	20.80	14.35

AAMI 命名子集：116 人 / 666 段

指标	SBP	DBP
MAE	19.34	13.17
Bias	-12.74	-9.31
误差 SD	22.72	13.93
误差不超过 5 mmHg (%)	19.22	24.77
误差不超过 10 mmHg (%)	36.19	45.20
误差不超过 15 mmHg (%)	53.00	67.27
参与者平均 MAE	19.58	13.10
参与者 MAE: 中位数	15.95	11.46
参与者 MAE: 第 90 百分位	36.76	23.72

误差为预测值减参考值；SD 使用 N-1。除百分比外单位均为 mmHg，区间包含边界。参与者平均 MAE 对每人等权。这些是公共数据评估，不是袖带设备临床验证。完整验证集、排除前期接触者后的指标及逐参与者 MAE 均在 V1 的 reports 文件夹。